TD
ANALYSE STATIQUE CODE

23/01/2024

Sadry FIEVET
sadry.fievet@univ-cotedazur.fr

PRÉSENTATION

Cette séance de TP est une introduction aux techniques d'analyse statique de code.
Si l'analyse statique de code permet de déceler de nombreux types d'erreurs (mauvaises pratiques de code, boucles infinies, fonctions et/ou import non utilisés, ...) nous allons nous concentrer sur la détection de failles de sécurité.

Introduction

C'est depuis la création des tous premiers programmes (1940) que l'idée de les vérifier existe. On peut cependant noter une sévère prise de conscience à la suite du tragique accident que subit la fusée Ariane le 4 juin 1996.

explosion Ariane 5 1996

L'étude des circonstances de cette explosion révèle que c'est la conversion d'un nombre flottant vers un entier non signé qui a généré une altitude négative dans l'ordinateur de bord.

Les pertes furent estimées à près de 700 millions d'euros.

DAST, IAST, SAST

Il existe 3 catégories d'outils employés dans la détection de vulnérabilités.

DAST (Dynamic Application Security Testing)

Principalement utilisés pour des audits en black box, ils permettent, à la différence des SAST, la détection de vulnérabilités pendant l'exécution de l'application (runtime). ZAP Proxy, BURP, SQLMap....

IAST (Interactive Application Security Testing)

Regroupant les avantages des SAST et DAST, les IAST proposent ainsi une vue plus complète de l'application. Ils sont néanmoins plus délicats à implémenter car ils peuvent affecter sérieusement les applications.

SAST (Static Application Security Testing)

L'analyse statique d'un code revient à évaluer son exécution sans pour autant l'exécuter. Pour prévoir la sortie d'un programme mais aussi savoir isoler les parties de codes qui pourraient être exploitées par un acteur malveillant il existe deux principales techniques :

- analyse 'manuelle'
- analyse avec outils

Si l'analyse manuelle permet un audit plus fin et de meilleurs résultats, les compétences et le temps qu'elle requiert ont permis aux scanners et autres outils automatiques de s'imposer comme la solution la plus utilisée dans les entreprises.

De nos jours, l'approche **DevSeCOps** qui est adoptée par la plupart des entreprises du secteur informatique a automatisé la pratique de l'analyse statique de code en l'incluant dans son itération d'intégration continue.

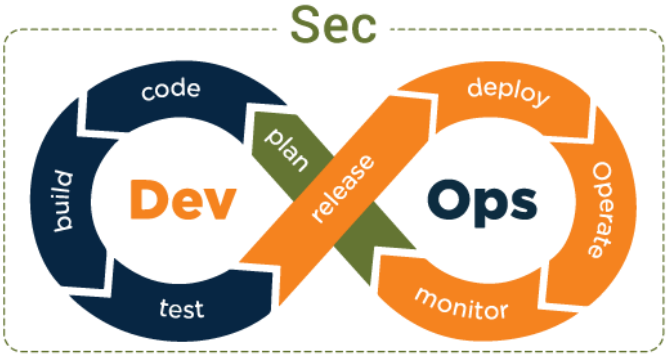

En effet, les étapes de **code, build et test** sont souvent constituées d'analyses statiques réalisées par des outils spécifiques.

Ci-après une liste non exhaustive d'outils SAST :

Synk Code
Veracode Static Analysis
Fortify Static Code Analyzer (SCA)
NodeJsScan
Checkmarx SAST
Semgrep
Bandit
Bearer
Contrast Scan
Coverity
HCL AppScan
Kiuwan
Klocwork
Reshift

Fonctionnement d'un SAST

Scan

La première étape (scan) pour un compiler qui tente de comprendre de code va consister à le découper en petits morceaux appelés jetons. On peut lister les différents tokens utilisés dans Python grâce à la librairie tokenize

```python
import io
import tokenize

code = b"nom = input('Entrez votre nom: ')"

for token in tokenize.tokenize(io.BytesIO(code).readline):
    print(token)
```

```
┌──(sadry㉿localhost)-[~/…/FAC/sophia_2024/caspar/static_analysis]
└─$ python3 import\ io\ import\ tokenize.py
TokenInfo(type=63 (ENCODING), string='utf-8', start=(0, 0), end=(0, 0), line='')
TokenInfo(type=1 (NAME), string='nom', start=(1, 0), end=(1, 3), line="nom = input('Entrez votre nom: ')")
TokenInfo(type=54 (OP), string='=', start=(1, 4), end=(1, 5), line="nom = input('Entrez votre nom: ')")
TokenInfo(type=1 (NAME), string='input', start=(1, 6), end=(1, 11), line="nom = input('Entrez votre nom: ')")
TokenInfo(type=54 (OP), string='(', start=(1, 11), end=(1, 12), line="nom = input('Entrez votre nom: ')")
TokenInfo(type=3 (STRING), string="'Entrez votre nom: '", start=(1, 12), end=(1, 32), line="nom = input('Entrez votre nom: ')")
TokenInfo(type=54 (OP), string=')', start=(1, 32), end=(1, 33), line="nom = input('Entrez votre nom: ')")
TokenInfo(type=4 (NEWLINE), string='', start=(1, 33), end=(1, 34), line='')
TokenInfo(type=0 (ENDMARKER), string='', start=(2, 0), end=(2, 0), line='')
```

Parse

Les jetons en eux-mêmes ne reflètent rien de la grammaire de la langue. C'est là que le parser entre en jeu. Il prend ces jetons, valide que la séquence dans laquelle ils apparaissent est conforme à la grammaire et les organise dans une structure arborescente, représentant une structure de haut niveau du programme. C'est ce qu'on appelle un arbre de syntaxe abstraite (**AST**).

Analyse des AST
Le SAST va maintenant parcourir les différents AST produits dans l'étape précédente en appliquant les règles de détection qui lui sont propres.

EXERCICES

Nous allons maintenant passer à la pratique et utiliser 2 SAST de la liste ci-dessus :

- Bandit
- Semgrep

BANDIT

SAST pour analyser les programmes Python, Bandit passe en revue tous les fichiers et construit les AST résultants. Il lance ensuite une série de tests sur les nœuds puis génère un rapport. On peut l'utiliser en CI car il permet de scanner chaque merge request/commit avec une configuration modulaire des tests à effectuer.

En effet, c'est dans le fichier de configuration que l'on détermine les modules qui seront lancés.

Installation

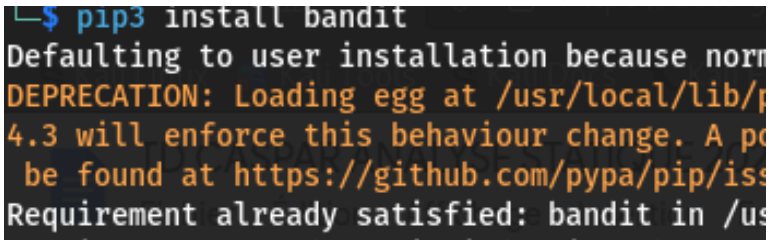

Vérifiez ensuite que tout est ok

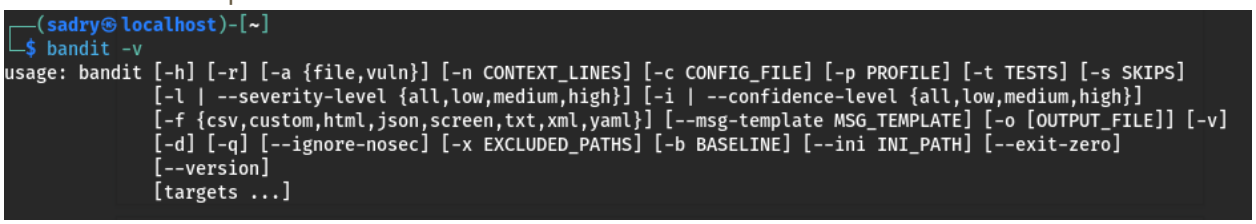

Il faut maintenant générer le fichier de configuration.

```
┌──(sadry㉿localhost)-[~/…/sophia_2024/caspar/static_analysis/bandit]
└─$ bandit-config-generator -o config.yml
[ INFO]: Successfully wrote profile: config.yml
```

On obtient un fichier qui devrait ressembler à celui ci-après

```
┌──(sadry㉿localhost)-[~/…/sophia_2024/caspar/static_analysis/bandit]
└─$ cat config.yml
### Bandit config file generated from:
# '/usr/local/bin/bandit-config-generator -o config.yml'

### This config may optionally select a subset of tests to run or skip by
### filling out the 'tests' and 'skips' lists given below. If no tests are
### specified for inclusion then it is assumed all tests are desired. The skips
### set will remove specific tests from the include set. This can be controlled
### using the -t/-s CLI options. Note that the same test ID should not appear
### in both 'tests' and 'skips', this would be nonsensical and is detected by
### Bandit at runtime.

# Available tests:
# B101 : assert_used
# B102 : exec_used
# B103 : set_bad_file_permissions
# B104 : hardcoded_bind_all_interfaces
```

Exercice 1

Vous devez analyser les 5 scripts python contenus dans le dossier ‘ex_1’ de la manière suivante :

- Commencez par faire un scan Bandit sans préciser de fichier de configuration et sauvegardez ce premier rapport aux formats html et text.
- Etudiez ce rapport et lorsque vous pensez avoir trouvé quelle vulnérabilité est contenue dans chacun des 5 scripts, générez un nouveau fichier de configuration ne contenant que le module associé à cette vulnérabilité. Sauvez votre rapport aux format html et text

SEMGREP

Exercice 2

Nous allons maintenant utiliser Semgrep. Pour ce faire, vous devez dans un premier temps vous inscrire avec votre compte Github. Une fois votre inscription effectuée, installez SemGrep en suivant ces instructions :
https://semgrep.dev/docs/getting-started/quickstart/
Vérifiez ensuite votre installation en scannant le dossier 'semgrep_example'.
Vous devriez avoir un résultat proche de celui ci-après :

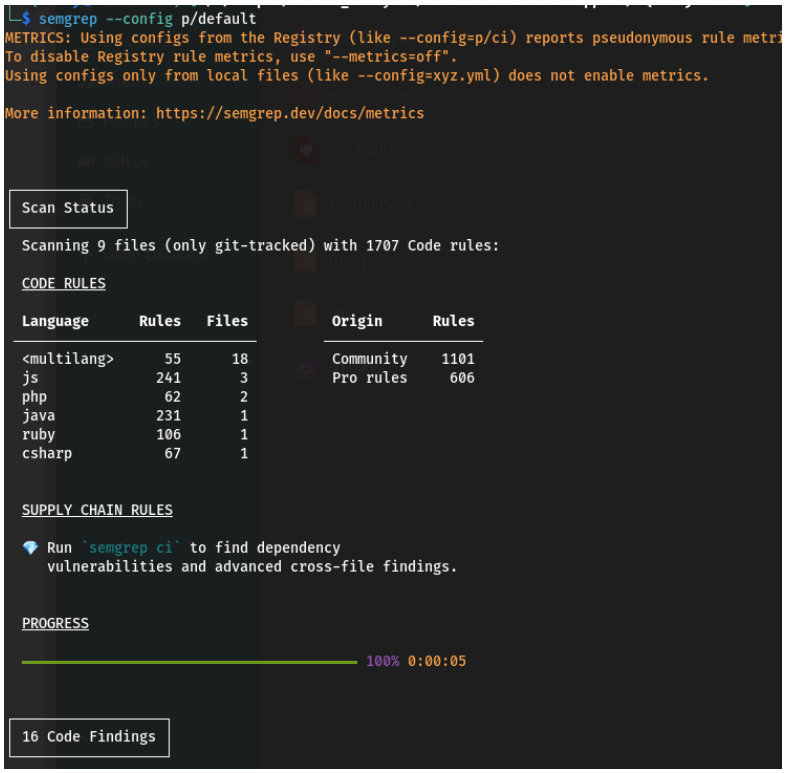

Vous allez maintenant utiliser Semgrep afin d'auditer les différentes applications du dossier 'ex_2'.
Pour chacun des dossiers vous devez :

- réaliser un scan complet de l'application
- identifier les vulnérabilités High
- corriger ces vulnérabilités
- réaliser à nouveau un scan afin de vérifier votre correction

Vous devez illustrer et commenter chacune de ces étapes en fournissant des captures d'écrans, des fichiers, des pdf, etc...
Ci-après quelques exemples de captures d'écrans attendus :

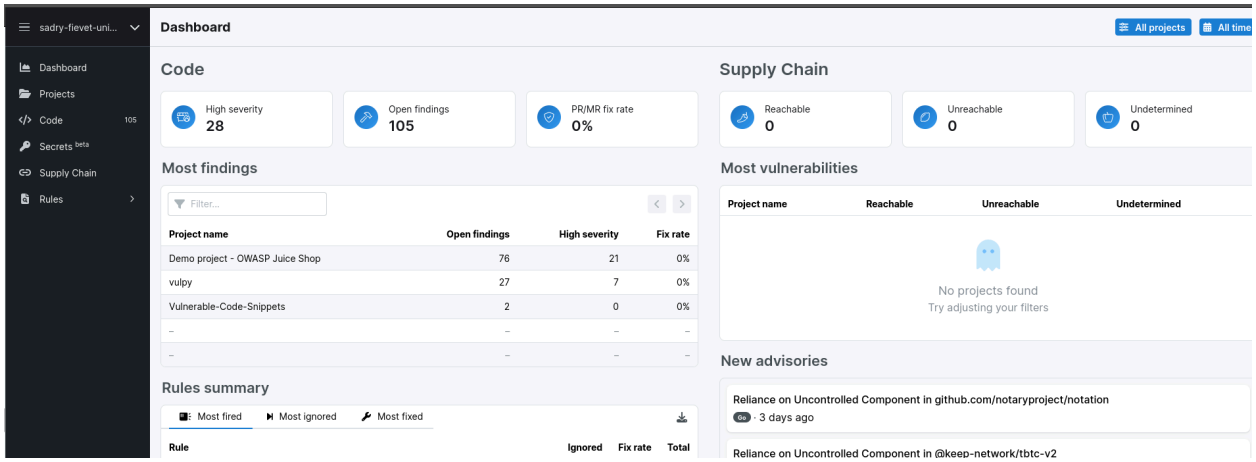

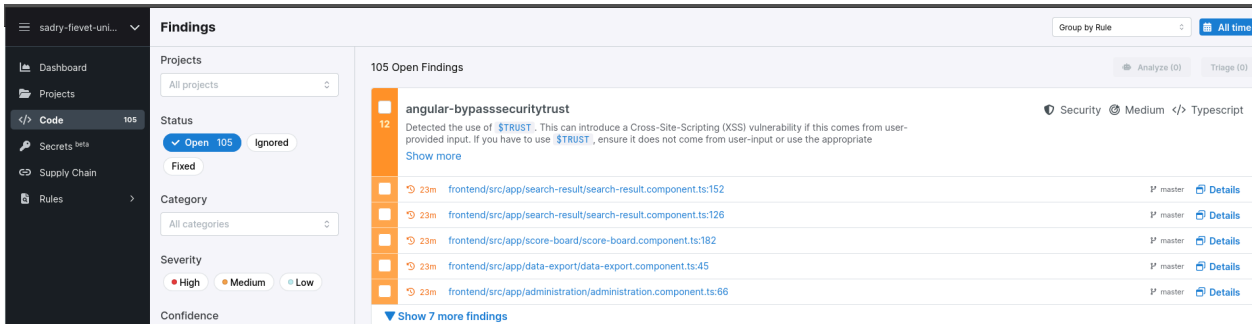

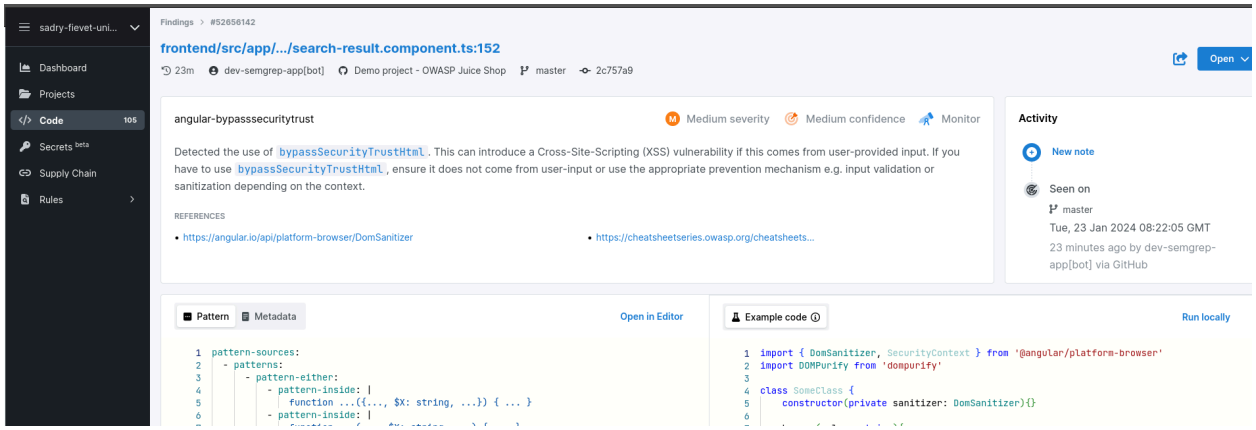

Exercice 3

Auditez l'application contenue dans le dossier 'ex_3', corrigez les vulnérabilités High détectées et vérifiez vos corrections avec un scan de contrôle.

Exercice 4

Les SAST comme Semgrep permettent d'identifier rapidement un certain nombre de vulnérabilités dans un code. Cependant, certaines failles leurs échappent du fait qu'elles ne peuvent s'identifier qu'au runtime avec des DAST.

Pour ce dernier exercice, vous devez fournir un code contenant une vulnérabilité de votre choix qui n'est détectable qu'avec une analyse dynamique, réalisée avec un DAST.

Les documents attendus sont :

- le code vulnérable ainsi que tous les fichiers nécessaires pour lancer l'application.
- le rapport de SemGrep
- des captures d'écran de la détection de la vulnérabilité par un DAST (Burp, Zap...)
- Une courte explication de la vulnérabilité ainsi que les raisons de sa non détection par un SAST

FIN DU DOCUMENT